

基于优化 XGBoost 的无人机集群作战效能评估及分析

张水库^{1,2}, 张伦^{2,3}, 龚建兴^{2,3}, 黄健^{2,3*}

(1.西北机电工程研究所, 陕西 咸阳 712099; 2.国防科技大学智能科学学院, 湖南 长沙 410073; 3.装备状态感知与敏捷保障全国重点实验室(国防科技大学), 湖南 长沙 410073)

摘要:针对无人机集群作战过程的高时效性、行为复杂性、信息数据庞大等特点在作战效能评估方面产生的巨大挑战,提出一种基于粒子群优化(particle swarm optimization, PSO)-极端梯度提升(extreme gradient boosting, XGBoost)-沙普利加性解释(Shapley additive explanations, SHAP)模型的数据驱动效能评估方法。由系统评估指标出发,采用 XGBoost 算法建立效能评估模型,基于仿真数据分析验证指标数据与作战效能间的映射关系,挖掘无人机集群体系作战效能;利用 PSO 算法优化 XGBoost 模型超参数,提高评估精度与效率;为兼顾评估工作的预测性与可解释性,采用 SHAP 机制对效能评估过程进行解释,给出指标优化改进方向。通过 Vensim 平台采集的无人机集群作战仿真数据进行验证,相比支持向量回归(support vector regression, SVR)、随机森林(random forest, RF)算法、轻量级梯度提升机(light gradient boosting machine, LightGBM)算法及反向传播(back propagation, BP)神经网络方法,所提模型具有更好的评估精度及可解释性。

关键词:无人机集群;作战效能评估;机器学习;XGBoost;SHAP

中图分类号:TP181; TJ85

文献标志码:A

引用格式:张水库,张伦,龚建兴,等. 基于优化 XGBoost 的无人机集群作战效能评估及分析[J]. 山东大学学报(工学版), 2026, 56(2): 11-18.

ZHANG ShuiKu, ZHANG Lun, GONG Jianxing, et al. Evaluation and analysis of unmanned aerial vehicle cluster combat effectiveness based on optimized XGBoost[J]. Journal of Shandong University (Engineering Science), 2026, 56(2): 11-18.

Evaluation and analysis of unmanned aerial vehicle cluster combat effectiveness based on optimized XGBoost

ZHANG ShuiKu^{1,2}, ZHANG Lun^{2,3}, GONG Jianxing^{2,3}, HUANG Jian^{2,3*}

(1. Northwest Institute of Mechanical & Electrical Engineering, Xianyang 712099, Shaanxi, China; 2. College of Intelligence Science and Technology, National University of Defense Technology, Changsha 410073, Hunan, China; 3. National Key Laboratory of Equipment State Sensing and Smart Support, National University of Defense Technology, Changsha 410073, Hunan, China)

Abstract: To address the huge challenges of high time-sensitivity, behavioral complexity, and massive data volumes in the combat effectiveness evaluation of unmanned aerial vehicle (UAV) cluster, a data-driven effectiveness evaluation method based on the particle swarm optimization (PSO)-extreme gradient boosting (XGBoost)-Shapley additive explanations (SHAP) model was proposed. An effectiveness evaluation model was established using the XGBoost algorithm based on an evaluation index system. The mapping relationship between index data and combat effectiveness was analyzed and verified using simulation data to mine the combat effectiveness of the UAV cluster system. The PSO algorithm was employed to optimize the hyperparameters of the XGBoost model to enhance evaluation accuracy and efficiency. To balance the predictability and interpretability of the evaluation work, the SHAP mechanism was utilized to interpret the effectiveness evaluation process and identify directions for index optimization. Verified by UAV cluster combat simulation data collected via the Vensim platform, the proposed model demonstrated superior accuracy and

收稿日期:2025-06-27

基金项目:装备状态感知与敏捷保障全国重点实验室基金资助项目(6142003202410)

第一作者简介:张水库(2000—),男,陕西咸阳人,硕士研究生,主要研究方向为任务规划。E-mail: zhangsk@nudt.edu.cn

***通信作者简介:**黄健(1971—),女,浙江绍兴人,教授,博士生导师,博士,主要研究方向为系统仿真、任务规划、人工智能。

E-mail: huang_jian@139.com

interpretability compared to support vector regression (SVR), random forest (RF) algorithm, light gradient boosting machine (LightGBM), and back propagation (BP) neural network methods.

Keywords: UAV cluster; effectiveness evaluation; machine learning; XGBoost; SHAP

0 引言

无人机(unmanned aerial vehicle, UAV)集群作战效能评估作为集群作战任务规划的重要环节,是指在一定作战条件下,衡量无人机集群通过智能协同在规定时间内有效完成相应作战任务的能力^[1]。高效准确的效能评估方法和结论是无人机集群各项作战研究的基础^[2]。随着无人机装备、集群结构复杂度及信息化程度不断提升,评估数据呈现非线性性和多维性等特征,使传统经验驱动方法(如贝叶斯网络^[3]、层次分析法^[4]、灰色关联度分析^[5]及ADC(availability, dependability, capability)方法^[6]等)往往存在处理数据效率低和评估权重计算主观性强等问题。

基于机器学习的效能评估方法不依赖系统的先验知识,通过数据驱动方法建立指标与效能之间的非线性映射关系,具有自主学习与调整能力,已经取得广泛应用^[7]。文献[8]基于核 Fisher 判别分析,从评估指标数据中提取高阶非线性特征,利用相关向量机(relevance vector machine, RVM)进行非线性系统建模,建立战斗机空战效能评估模型,但应用试验样本数较少,样本数据维度也较低,没有得出有效的改进措施;文献[9]针对水下无人潜航器(unmanned underwater vehicle, UUV)协同作战效能评估问题,综合遗传算法(genetic algorithm, GA)与粒子群优化(particle swarm optimization, PSO)算法,优化反向传播(back propagation, BP)神经网络初始权重和阈值,提出一种基于 GAPSO-BP 神经网络的评估模型;文献[10]构建最小二乘支持向量机(least squares support vector machine, LS-SVM)评估模型,完成实战演习作战效能评估;文献[11]在研究高功率微波武器与中近程防空武器协同作战效能时,建立融合模糊逻辑与小波神经网络的评估模型;文献[12]针对指标维度高、评估空间复杂的防空导弹武器系统作战效能问题,基于径向基函数(radial basis function, RBF)神经网络建立作战效能评估方法。以上工作从不同军事领域对评估问题进行研究,但在方法上仍存在较多限制条件,如模型难以实现最优化结构、神经网络结构的黑盒性

质使评估结果难以解释等。效能评估工作通常关注两个问题:如何进行有效评估及如何对评估结果进行分析^[13]。上述研究主要基于前一问题展开,而如何根据有效评估过程及结果寻找效能优化方向,是实现由评级向寻优的跨越。

极端梯度提升(extreme gradient boosting, XGBoost)属于一种集成分类器,通过集成多个决策树模型增强预测能力,具备线回归和回归树特性,具有良好的自适应性,适用于效能评估问题。然而,XGBoost 结构存在参数敏感性导致调优复杂等缺点,评估精度和效率有待提高。PSO 作为并行随机搜索最优化方法,具有较好的全局搜索能力。利用 PSO 算法优化 XGBoost 网络结构,旨在优化 XGBoost 算法中的超参数,以达到更高效、更精确的评估效果。

综上,本研究基于系统动力学仿真平台 Vensim 建立无人机集群作战仿真过程,设计完备且有效的无人机集群作战指标评估体系。基于采集的相关指标数据,构建 PSO-XGBoost 评估模型,获取更加准确的作战效能。在原本基于数据驱动具有黑盒性质的效能评估模型基础上,采用沙普利加性解释(Shapley additive explanations, SHAP)方法,通过显示指标变量对评估效能结果的影响及指标间耦合性提高可解释性,对 PSO-XGBoost 评估模型输出的效能评估结果进行合理性分析,给出指标影响及改进方式,较好地实现寻优评估目的。

1 无人机集群作战评估指标体系

无人机集群作为复杂系统,由作战任务、集群构成条件、平台打击能力及集群性能不确定性等诸多因素共同构成作战效能空间,决定无人群体作战效能体系架构及指标需充分反映无人机集群与作战效能诸多影响因素^[14]。

遵循评估理论要求,将效能评估指标体系结构设计为 3 层。第 1 层为目标层,描述最终的评估目的,即本研究求取的无人机集群作战效能。第 2 层为效能层,作为指标体系的分支节点。该层指标表示评估过程中需要关注的部分效能。本研究将无人机集群作战效能分为集群系统效能和任务执行

效能 2 个角度。集群系统效能反映无人机平台的基础性能(如续航能力、机动能力等)及集群平台内部的通信协同与控制决策等能力;任务执行效能指无人机集群完成相应任务需求的综合作战能力,包含侦察、打击、干扰、控制、压制等,根据领受作

战任务不同,配置不同的载荷资源。第 3 层为指标层,体现评估过程中每个功能的指标。本研究在该层设计 14 个评估指标,建立以数据为支撑,全方位反映无人机集群作战性能的评估指标体系,如图 1 所示。




图 1 无人机集群作战效能评估指标体系
Fig.1 Combat effectiveness evaluation index system of UAV cluster

2 改进 XGBoost 效能评估方法

2.1 XGBoost 算法

XGBoost 算法作为一种集成学习算法,由加法模型和前向分布算法两部分组成,基于迭代思想,通过不断优化目标函数,生成最优弱学习器^[15]。将所有决策树的结果相加,得到模型的最终输出。XGBoost 的目标函数 $L^{(t)}$ 包含损失函数与正则项,具体计算式为

$$L^{(t)} = \sum_{i=1}^n l[y_i, \hat{y}_i^{(t-1)} + f_t(x_i)] + \Omega(f_t), \tag{1}$$

式中: y_i 为第 i 个样本的实际效能; $\hat{y}_i^{(t-1)}$ 为第 i 个样本在第 $t-1$ 次迭代时的评估效能; n 为样本总数; f_t 为在第 t 次迭代过程中新添加的树模型函数; x_i 为样本 i 的输入指标; l 为损失函数,衡量 $\hat{y}_i$ 和 y_i 之间的误差; $\Omega(f_t)$ 为正则化函数,防止模型过拟合, $\Omega(f_t) = \alpha T + \frac{1}{2} \lambda \sum_{j=1}^T \omega_j^2$,其中 T 为叶节点总数, ω_j 为第 j 个叶节点的权重, α 为叶节点惩罚系数,取常数, λ 为正则化系数,取常数。

2.2 参数优化算法

XGBoost 算法具有较多的关键超参数,它们之间存在复杂的非线性交互关系。手动调参方法步骤繁琐,很难得到精确度较高的模型,在参数优化方法中,相比网格搜索优化方法,优化参数数量有限,且参数范围极小。贝叶斯优化方法无法适配离散参数,且实现复杂。PSO 算法的参数优化方法可同时优化离散型和连续型参数,具有较快的收敛速度^[16]。因此,本研究采用 PSO 算法对 XGBoost 模型进行超参数优化。XGBoost 模型参数种群可表示为 $P = \{P_1, P_2, \dots, P_N\}$,种群数为 N ,其中 P_m 为第 m 个列向量粒子, $P_m = (P_{m,1} \ P_{m,2} \ \dots \ P_{m,q})^T$, $P_{m,q}$ 为 P_m 的第 q 个优化参数。规定粒子 $P_m \in [P_{\min}, P_{\max}]$,其中 $P_{\min} = (0.001 \ 0.1 \ 1 \ 0.001 \ 0.1 \ 0.01)^T$, $P_{\max} = (1 \ 1 \ 10 \ 1 \ 1 \ 1)^T$ 。粒子的速度和位置更新公式为

$$\begin{cases} V_{m,d}^{t+1} = wV_{m,d}^t + c_1r_1(P_{m,d}^p - P_{m,d}^t) + \\ \quad c_2r_1(P_{d,best}^g - P_{m,d}^t) \\ P_{m,d}^{t+1} = P_{m,d}^t + V_{m,d}^{t+1} \end{cases}, \tag{2}$$

式中, $P_{m,d}^t$ 和 $V_{m,d}^t$ 为 P_m 在第 t 次迭代时第 d 维的参数及变化步长, $P_{d,best}^g$ 为种群前 t 次迭代产生的全局

适应度最优个体中第 d 维的参数, $P_{m,d,best}^p$ 为粒子 m 在前 t 次迭代产生的适应度最优个体中第 d 维的参数, w 为惯性系数, c_1 、 c_2 为学习因子, r_1 、 r_2 为加速系数。

2.3 SHAP 机制

效能评估工作在准确评估效能的同时,对结果做出解释也是重要研究部分。SHAP 结构作为有效的事后解释框架,基于模型评估结果的边际贡献计算权重,直接关联模型评估逻辑,避免专家经验的主观性,确保评估体系与模型决策路径一致,并可以通过 Shapley 交互索引探索 2 个指标间的交互效应^[17],解释指标对评估结果的权重及某些指标间的交互关系。SHAP 解释模型为

$$G=\phi_0+\sum_{k=1}^K\phi_k,$$

(3)

式中: ϕ_0 为模型基准输出,即训练集样本预测的平均评估效能; K 为样本指标总数; ϕ_k 为指标 k 对评估效能的贡献度, $\phi_k=\sum_{S\in N'\{k\}}\frac{|S|!(K-|S|-1)!}{K!}[\hat{y}_k(S\cup\{k\})-\hat{y}_k(S)]$,其中 $N'\{k\}$ 为不包括指标 k 的全体指标集合, S 为指标子集, $|S|$ 为 S 中包含的指标总数, $\hat{y}_k(S\cup\{k\})-\hat{y}_k(S)$ 为指标 k 加入 S 时的边际贡献。当指标 k 对应的 ϕ_k 为正时,说明该指标对效能结果评估有正向作用;反之,则该指标会降低模型评估结果。对所有数据样本中各个指标的 ϕ_k 取平均,得到该指标对最终评估效能的贡献度。

2.4 效能评估模型工作流程

本研究构建的无人机集群效能评估流程如图 2 所示。




图 2 基于 PSO 算法优化的 XGBoost 无人机集群作战效能评估模型流程图

Fig.2 The flowchart of XGBoost model based on PSO algorithm for evaluating the effectiveness of UAV cluster combat

无人机集群效能评估基本步骤如下。

(1)对原始数据进行数据清洗、归一化处理,将数据集以 8:2 划分为训练集和测试集。

(2)建立 XGBoost 无人机集群效能评估模型。

(3)使用 PSO 算法对模型中的学习率、回归树数量等 6 个关键参数进行寻优,获取最优参数组合。

(4)使用参数优化的 XGBoost 进行训练,对测试集进行效能预测,采用 K 折交叉验证方法评估算法性能。

(5)在预处理数据中计算皮尔逊相关系数,分析指标数据间的相关性,防止存在高度相关性指标使模型过度拟合及计算资源浪费。发现是否存在耦合性较高的指标,在 SHAP 分析中进一步揭示指标间的关系。

(6) 根据评估指标和效能进行 SHAP 分析,给出各评估指标对效能的全局影响度、单个指标及高耦合度相关指标的局部分析。

3 仿真试验设计与分析

3.1 数据准备

利用 Vensim 软件进行基于系统动力学模型的红蓝对抗模式下无人机集群作战仿真,综合无人机

的生存率和目标损毁率作为作战效能,建立无人机集群作战存量流量图,如图 3 所示。每次仿真中流量图的输出结果为作战效能,取值范围为 0~1。将作战效能作为样本标签。为确保数据覆盖范围尽量广泛,共获取 700 次试验数据样本集,随机选取 3 个样本展示数据结构,如表 1 所示,其中 3 个样本的标签分别为 0.285、0.298、0.269。为消除不同指标之间因量纲或数值范围差异带来的影响,在模型测试前进行归一化处理。




图 3 基于系统动力学模型的无人机集群作战存量流量图
Fig.3 Operational stock flow diagram of UAV cluster system based on system dynamics model

表 1 评估指标数据
Table 1 Evaluation indicators and performance results data

样本标签	$X_1/(m \cdot s^{-1})$	$X_2/\%$	X_3/s	$X_4/\%$	$X_5/\%$	$X_6/\text{架}$	$X_7/\%$	$X_8/\%$	X_9/s	$X_{10}/\%$	$X_{11}/\%$	$X_{12}/\%$	X_{13}/m	$X_{14}/\text{枚}$
0.285	60.5	9.3	3.9	27.6	74.7	24	88.2	61.2	1.7	78.0	72.0	65.3	29	32
0.298	42.7	38.5	2.9	44.5	66.3	8	85.1	56.2	2.5	96.6	74.4	81.3	27	32
0.269	35.0	10.7	5.6	30.0	73.1	8	91.6	49.8	1.8	63.5	50.7	73.2	12	14

3.2 效能评估

为验证 PSO-XGBoost 在进行无人机集群作战效能评估工作中的有效性,本研究选取 4 种常用于效能评估领域的监督学习算法作为对比算法,分别为支持向量回归 (support vector regression, SVR)、随机森林 (random forest, RF)、轻量级梯度提升机 (light gradient boosting machine, LightGBM)、BP 神经网络。为比较不同算法性能,采用平均绝对误差 E_{MS} 、平均绝对百分比误差 E_{RMS} 作为模型精度的评价指标,拟合优度 R^2 作为拟合程度的评价指标。

PSO 算法设置如下:采用实数编码方式,随机生成粒子数为 40 的种群,迭代次数 τ 为 100 次, $w=0.75$, $c_1=1.5$, $c_2=1.5$ 。以 XGBoost 训练过程中

的均方根误差作为适应度 E ,对 XGBoost 的学习率 η 、特征抽取比例 c 、决策树的最大深度 δ 、分裂增益约束 γ 、随机样本抽取比例 s 、子节点最小样本权重 λ 进行优化。适应度 E 的计算式为

$$E = \sqrt{\frac{1}{n} \sum_{i=1}^n (F(\eta, c, \delta, \gamma, s, \lambda) - y_i)^2}, \quad (4)$$

式中 $F(\eta, c, \delta, \gamma, s, \lambda)$ 为当前参数下的预测效能。为保证参数优化性能稳定,在同一设置下条件,PSO 算法独立运行 15 次,参数优化的平均适应度曲线如图 4 所示。粒子更新迭代次数达到 70 次后,算法基本保持稳定。优化后的平均适应度为 7.62,较初始生成参数的适应度为 8.41,优化后的损失降低 9.4%,有效增强了 XGBoost 的评估性能。优化后的模型参数如表 2 所示。




图 4 粒子群优化算法迭代曲线

Fig.4 The iterative curve of PSO algorithm

表 2 PSO 算法优化 XGBoost 的参数结果

Table 2 Parameter results of XGBoost model optimized with PSO algorithm

η	c	δ	γ	s	λ
0.3	0.847	7	0.017	0.816	0.1

本研究采用 K 折交叉验证方法对各模型进行训练, K 取 10。对比模型及部分相关参数设置如表 3 所示。通过训练样本训练后,各模型在测试集上分别进行测试,第 K 次的效能评估测试结果如表 4 所示。测试集中,PSO-XGBoost 模型的评估结果总体上更聚集于对角线附近,表明评估准确性更高。

表 3 对比算法参数设置

Table 3 Parameter settings of comparative algorithm

SVR		RF			LightGBM				BP 神经网络				
内核类型	核系数	惩罚系数	决策树数量	分裂的特征数	节点分裂最小样本数	学习率	最大叶子数	决策树数量	叶子节点所需最小样本数	学习率	隐藏层数量	隐藏层激活函数	隐藏层神经元数
RBF	内核 scale	1	100	3	2	0.1	31	100	20	0.01	2	ReLU	100

注:scale 表示 scikit-learn 库中计算 RBF 核函数系数方式的默认设置。

表 4 测试集下各算法评估性能评价指标

Table 4 Performance evaluation indicators of each algorithm under the test set

算法	E_{MS}	E_{RMS}	R^2
SVR	109.020	10.441	0.330
RF	78.246	8.846	0.620
LightGBM	88.120	9.387	0.483
BP 神经网络	86.250	9.064	0.552
PSO-XGBoost	77.057	8.778	0.672

4 评估结果分析

对评估指标样本数据使用皮尔逊相关系数求取指标间的相关性情况,结果如图 5 所示。由图 5 分析可知,各指标间的相关性系数 p 均小于 0.8,表明指标间的数据并未造成较大的冗余性,验证了指标设计的合理性及样本数据的有效性。 X_9 与 X_{14} 之间的 p 为 0.750,是相关性最大的一组指标,表明它们存在一定程度的耦合关系,需要在评估结果分析中对这组指标间的相互影响着重分析。

评估指标全局重要性图如图 6 所示,展示了 14 个评估指标对效能的贡献度排序及具体贡献度。由图 6 可以看出,指标 X_8 (环境适应能力)对评估结果的贡献度最大,贡献度排序前 4 的指标对评估效能结果的贡献为 57.53%。因此,在评估指标设置时,主要关注这 4 个指标的调整。




图 5 评估指标的皮尔逊相关系数矩阵

Fig.5 Pearson correlation coefficient matrix of evaluation indexes




图 6 评估指标全局重要性图

Fig.6 The global importance plot of the evaluation indexes

效能评估模型的 SHAP 特征摘要图如图 7 所示,体现各个特征相对于预测结果的正负关系。图 7 中的点与评估指标及其贡献度一一对应,其中评估指标基于对评估效能的平均绝对贡献度进行排序,水平分布宽度反映指标对评估结果的异质性影响。以 X_8 为例,红色点在大于 0 的一侧堆积,表示该指标较高的特征值,为效能结果带来正向影响;蓝色点在小于 0 的一侧堆积,表示该指标较低的特征值,为效能结果带来负向影响。




图 7 评估指标全局摘要图

Fig.7 Global summary plot of the evaluation indexes

基于贡献度量化的每个指标对评估效能进行定性和定量解释,可视化所有要素的影响。以表征打击任务的两个评估指标 X_{13} 、 X_{14} 为例,各指标与模型评估效能之间的依赖关系如图 8、9 所示。由图 8 可以看出, X_{13} 样本点向左下角堆积, 其贡献度 $\phi_{X_{13}}$ 在指标上升时总体线性上升, 由负变正, 表明 X_{13} 对效能评估结果影响由负向转为正向, 影响力不断增强。由图 9 可以看出, X_{14} 在 $(0, 0.4)$ 的较小范围内贡献度 $\phi_{X_{14}}$ 较小, 随着 X_{14} 增大, 指标对效能评估结果产生负向影响, 且影响趋势增大。




图 8 X_{13} 依赖图

Fig.8 Dependency plot of X_{13}




图 9 X_{14} 依赖图

Fig.9 Dependency plot of X_{14}

为分析指标之间的耦合关系,绘制 X_9 和 X_{14} 评估效能之间的耦合关系图,如图 10 所示。由图 10 可以看出:指标 X_9 的贡献度 ϕ_{X_9} 随 X_9 增大而减小, 即 X_9 为一个负向驱动因子, 值越小, 对模型正向贡献越大; 当 X_9 较小时 ($X_9 = 0 \sim 0.2$), 样本点总体偏向蓝色, 表明在该范围内, X_{14} 的贡献度 $\phi_{X_{14}}$ 较低; 当 X_9 较大时 ($X_9 = 0.4 \sim 1.0$), ϕ_{X_9} 逐渐降低, 对效能评估结果呈负向贡献, 样本点总体偏向红色, 表明在该范围内 $\phi_{X_{14}}$ 较高。综上, X_9 与 X_{14} 贡献度之间的耦合关系为此消彼长, 无法同时增大, 且增大 X_9 的取值有助于提高 X_{14} 的贡献度。




图 10 指标间依赖图

Fig.10 Dependency diagram between indexes

综上, 结合 SHAP 机制分析各指标对 PSO-XGBoost 模型输出评估效能结果的影响方式及程度, 对评估指标进行调整, 实现无人机集群作战效能优化。

5 结论

本研究针对无人机集群作战效能评估问题, 对

基于系统动力学模型的无人机集群作战过程仿真试验数据进行效能评估。对无人机集群作战过程建立效能评估指标体系,使用 PSO 算法优化 XGBoost,避免模型参数复杂调优困难的问题。与 4 种监督学习算法相比较,优化后的 XGBoost 在效能评估准确性方面表现出色。配合 SHAP 机制进行指标性能分析,计算每个指标对最终评估的贡献,分析样本中的指标对效能的作用及指标间的相关性,对指标影响及改进提供参考建议,保证评估准确性,提供透明、可追溯的效能评估决策体系,为无人机集群作战效能的科学评估提供一定的参考价值。

参考文献:

[1] 韩月明, 方丹, 张红艳, 等. 智能无人机集群协同作战效能评估综述[J]. 飞航导弹, 2020(8): 51-56.

[2] 孙鹏耀, 黄炎焱, 王凯生, 等. 不确定态势下无人机群协同作战效能评估[J]. 指挥控制与仿真, 2025, 47(1): 10-22.

SUN Pengyao, HUANG Yanyan, WANG Kaisheng, et al. Evaluation of combat effectiveness of unmanned aerial vehicle group in uncertain situations[J]. Command Control & Simulation, 2025, 47(1): 10-22.

[3] 于小岚, 熊伟. 基于贝叶斯网络的武器装备体系作战效能评估方法[J]. 火力与指挥控制, 2023, 48(5): 1-8.

YU Xiaolan, XIONG Wei. Overview of operational effectiveness evaluation methods of system of weapon equipment based on Bayesian network[J]. Fire Control & Command Control, 2023, 48(5): 1-8.

[4] JIANG W K, CHEN Z M, WU Y H, et al. Research on combat effectiveness evaluation of UAV swarm based on AHP-FCE[C]//Proceedings of 2022 International Conference on Autonomous Unmanned Systems (ICAUS 2022). Singapore: Springer, 2023: 1648-1660.

[5] 高娜, 闫永玲, 张庆波, 等. 基于双自适应调节算子的装备作战效能评估方法[J]. 火力与指挥控制, 2021, 46(8): 89-94.

GAO Na, YAN Yongling, ZHANG Qingbo, et al. Evaluation method of combat effectiveness of equipment based on dual adaptive adjustment operator [J]. Fire Control & Command Contro, 2021, 46(8): 89-94.

[6] WANG X L, XU J H, CHEN Y J. Combat effectiveness evaluation of air-crystal C4ISR early warning detection system based on improved ADC [C]//Fifth Symposium on Novel Optoelectronic Detection Technology and Application. Xi'an, China: SPIE, 2019: 26.

[7] 刘树光, 邵明军. 无人机自主作战效能评估技术研究综

述[J]. 光电与控制, 2024, 31(4): 55-64.

LIU Shuguang, SHAO Mingjun. A review on UAV autonomous combat effectiveness evaluation techniques [J]. Electronics Optics & Control, 2024, 31(4): 55-64.

[8] WANG Q, DING L Y, HAN B H, et al. Research on fighter air combat effectiveness evaluation based on RVM and KFDA [C]//2020 IEEE International Conference on Artificial Intelligence and Computer Applications (ICAICA). Dalian, China: IEEE, 2020: 270-274.

[9] DING Y M, LIU C Y, LU Q, et al. Effectiveness evaluation of UUV cooperative combat based on GAPSO-BP neural network [C]// 2019 Chinese Control and Decision Conference (CCDC). Nanchang, China: IEEE, 2019: 4620-4625.

[10] DAI Y Z, GUO J, WANG Y S, et al. Combat effectiveness evaluation of real combat exercise based on data-driven [C]//2018 Chinese Control and Decision Conference (CCDC). Shenyang, China: IEEE, 2018: 2433-2438.

[11] 李烨, 郑纯, 滕哲, 等. 基于模糊小波神经网络的高功率微波武器与中近程防空武器协同作战效能评估[J]. 兵工学报, 2022, 43(增刊2): 87-96.

LI Ye, ZHENG Chun, TENG Zhe, et al. Cooperative combat effectiveness assessment of high-power microwave weapons and medium- and short-range air defense weapons based on fuzzy wavelet neural networks[J]. Acta Armamentarii, 2022, 43(Suppl.2): 87-96.

[12] 张鹏, 冯柯, 宫建成, 等. 基于 RBF 神经网络的防空导弹武器系统作战效能评估[J]. 系统仿真学报, 2025, 37(2): 529-540.

ZHANG Peng, FENG Ke, GONG Jiancheng, et al. Combat effectiveness evaluation of air defense missile weapon system based on RBF neural network[J]. Journal of System Simulation, 2025, 37(2): 529-540.

[13] ZHANG C, JIAG H, XU Y. Evaluation of equipment system combat effectiveness based on task sequence [C]// 2024 IEEE 7th Advanced Information Technology, Electronic and Automation Control Conference (IAEAC). Chongqing, China: IEEE, 2024: 544-549.

[14] 齐智敏, 张海林, 伊山, 等. 智能无人机群体作战效能评估指标体系研究[J]. 舰船电子工程, 2021, 41(9): 1-5.

QI Zhimin, ZHANG Hailin, YI Shan, et al. Research on the index system of intelligent UAV group combat effectiveness evaluation [J]. Ship Electronic Engineering, 2021, 41(9): 1-5.